

Le agregué gentle-ai al stack del v2.

Mismo repo, mismos agentes, mismos modelos. Esto es lo que costó.

V2 (SIN GENTLE-AI) \$1.80 · 49 min · 0 memorias	V3 (CON GENTLE-AI) \$2.17 · 70 min · 3 memorias
---	---

A/B puro: solo cambia el overlay.

Mismo petdesk-v2 ya construido. Agregué una feature nueva (Stats Dashboard) con los mismos 4 agentes Kimi+DeepSeek que armaron el v2.

LO QUE NO CAMBIÓ VS V2

ORQUESTADOR	Multica self-host
CLI AGENTE	opencode
MODELOS	Kimi K2.6 + DeepSeek V3.2
DISCIPLINA	CONSTITUTION + contracts + checklist

LO ÚNICO QUE CAMBIÓ

OVERLAY	gentle-ai dentro de opencode
MEMORIA	Engram (HTTP persistente)
SKILLS	12 curadas auto-disponibles

No compite con Multica. Vive una capa más abajo.



*Multica orquesta features. **gentle-ai** orquesta fases. No se pisan — se complementan.*

El overhead es real y predecible.

v2 hizo 4 issues, v3 hizo 3 — comparo per-issue donde aplica.

MÉTRICA	V2	V3	Δ
Costo por issue	\$0.45	\$0.72	+60%
Tiempo por issue	~12 min	~23 min	+92%
Costo OpenRouter total	\$1.80	\$2.17	+21%
Tests al cierre	31	48	+55%
Memorias persistidas	0	3	nuevo
Detección de specs mal escritos	no	sí	nuevo

Razonamiento articulado, no solo código.

Cada agente persistió una memoria estructurada en Engram. Ejemplo del Dev Motor:

ENGRAM MEMORY · TYPE: FEATURE · PROJECT: PETDESK-V2

What: Implemented StatsEngine in src/engine/stats.ts

Why: Issue ZEN-14 required a stats engine for v3

Where: src/engine/stats.ts, tests/engine.stats.test.ts

Learned: occupancyRate requires intersecting

[rangeStart, rangeEnd) with each day's

9:00-18:00 UTC window for partial days.

Tops need deterministic tie-breaking by id.

Eso es razonamiento articulado. El agente entendió un edge-case sutil y lo dejó escrito como insight reusable. v2 no producía esto.

+60% costo. *+92% tiempo.* Sin SDD.

EL HALLAZGO NO-OBVIO

"SDD no se activó en ninguno de los 3 issues. El orquestador decidió ir directo cada vez. El +60% costo es el overhead del overlay base — no del flujo SDD."

gentle-ai te factura el overhead del overlay aunque no uses SDD. Skill-registry + Engram + plugins + system prompts custom inyectados en cada call.

No es marketing. Es trade-off.

NO

SI

- Tu prioridad es velocidad o costo mínimo
- Trabajas solo y no necesitas audit trail
- Features chicas y mecánicas
- No aprovechas memoria cross-session

SÍ

SI

- Equipo de 2+ devs compartiendo decisiones
- Compliance / auditoría estricta
- Pipeline de features grandes con decisiones de diseño
- Querés que el agente articule meta-razonamiento

Repos públicos. Números reales.

Mismo principio que el v2 — todo verificable. Si vas a probarlo, andá despacio y medí.

EL REPO DEL EXPERIMENTO	<code>github.com/rubenaros/petdesk-v2</code>
DOCS + SCRIPTS	<code>github.com/rubenaros/AgentCode</code>
GENTLE-AI	<code>github.com/Gentleman-Programming/gentle-ai</code>

Análisis completo, todos los números, las 3 memorias de Engram → [Medium](#) (link en el post).