

De 7 a 13 capas

Qué cambia al completar el arnés de un equipo de agentes.

v2: **7 capas**

v6: **13 capas**

El modelo razona, el arnés actúa

El **arnés** es toda la infraestructura que rodea al modelo: el loop, las herramientas, la memoria, la planificación, la verificación y la entrega.

En Claude Code, 1,6% es lógica del modelo.
98,4% es arnés.

v2 — un arnés parcial

Unas **7 de 13 capas**. El tablero y el ejecutor; los contratos a mano.

Descomposición a mano.

Verificación manual.

Merge **manual**.

v6 completa las capas que faltaban

→ **Memoria persistente** — Engram

→ **Planificación por máquina** — guiada por especificación

→ **Sub-agentes**

→ **Verificación** — CI como compuerta

→ **Entrega autónoma** — auto-merge

Los números (v2 → v6)

Costo por unidad \$0.45 → \$1.07

Tiempo por unidad ~12 min → ~11 min

Tests al cierre 31 → 39

Varianza de costo predecible → 1,8×

Costo facturado en OpenRouter. Features distintas: comparación por unidad, orientativa.

Dos capas rinden. El resto, depende.

Se justifican: **verificación con CI y entrega autónoma**.
Baratas, y las aporta GitHub.

Condicionales: la **memoria** (se escribió, no vi que se leyera)
y la **planificación** (mismo costo, más varianza).

Las capas pesadas, según el proyecto

Proyecto chico / descartable: no las uses. Son lastre.

Equipo / features grandes / larga vida: pagan.

Con auditoría: valen sin importar el tamaño.

EN UNA FRASE

Un arnés más completo no es automáticamente mejor

Es más capaz y más caro de operar. Conviene sumar cada capa cuando el escenario la justifique, no por defecto.

Próximo paso:
modelos locales.